

FTML 2026

Exercices 1 à 7

Ce rapport traite les exercices 1 à 7 du projet. Les exercices 1, 2 et 3 sont des exercices de mathématiques. Les exercices 4 à 7 sont des exercices de code : le détail du code et des graphiques est dans les notebooks correspondants, on résume ici la démarche suivie et les résultats obtenus. Sauf indication contraire, on note $\|\cdot\| = \|\cdot\|_2$.

Table des matières

1	Estimateur de Bayes et risque de Bayes	1
2	Risque de Bayes avec la perte absolue	2
3	Espérance du risque empirique pour l'OLS	4
4	Régression sur un jeu de données fourni	6
5	Classification sur un jeu de données fourni	7
6	Application de l'apprentissage supervisé	9
7	Application de l'apprentissage non supervisé	12

1 Estimateur de Bayes et risque de Bayes

Question 1 : Un cadre d'apprentissage et son prédicteur de Bayes

Cadre proposé. On choisit un problème de régression issu de la physique, différent de ceux vus en cours.

- **Espace d'entrée** : $\mathcal{X} = [15, 35] \subset \mathbb{R}$, une température ambiante exprimée en degrés Celsius.
- **Espace de sortie** : $\mathcal{Y} = \mathbb{R}$, la consommation électrique d'un climatiseur sur une heure, exprimée en kilowattheures.
- **Variable aléatoire** (X, Y) : on tire $X \sim \mathcal{U}([15, 35])$ et on pose

$$Y = aX + b + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2) \text{ indépendant de } X,$$

avec $a = 0,3 \text{ kWh}/^\circ\text{C}$, $b = 0,5 \text{ kWh}$ et $\sigma = 0,5 \text{ kWh}$. La loi jointe est donc celle d'un couple $(X, aX + b + \varepsilon)$.

- **Fonction de perte** : la perte quadratique $\ell(y, z) = (y - z)^2$.

Prédicteur de Bayes. Pour la perte quadratique, le prédicteur de Bayes est l'espérance conditionnelle. Pour tout $x \in \mathcal{X}$,

$$f^*(x) = \arg \min_{z \in \mathbb{R}} \mathbb{E}[(Y - z)^2 \mid X = x] = \mathbb{E}[Y \mid X = x] = ax + b.$$

En effet, $\mathbb{E}[Y \mid X = x] = \mathbb{E}[aX + b + \varepsilon \mid X = x] = ax + b + \mathbb{E}[\varepsilon] = ax + b$, puisque ε est centré et indépendant de X .

Risque de Bayes. Par définition, $R^* = \mathcal{R}(f^*) = \mathbb{E}[(Y - f^*(X))^2]$. Or $Y - f^*(X) = aX + b + \varepsilon - (aX + b) = \varepsilon$, d'où

$$R^* = \mathbb{E}[\varepsilon^2] = \text{Var}(\varepsilon) = \sigma^2 = 0,25 \text{ kWh}^2.$$

Le risque de Bayes est exactement la variance du bruit : c'est l'erreur irréductible, due à la partie de Y qui n'est pas expliquée par X .

Question 2 : Estimateur naïf et vérification par simulation

On choisit comme estimateur alternatif le *prédicteur constant* $\tilde{f}(x) = c$, où c est calibré comme la moyenne empirique des y sur un grand échantillon d'entraînement (donc $c \approx \mathbb{E}[Y]$). Cet estimateur ignore totalement l'entrée x ; il est donc clairement différent de f^* . Son risque réel vaut

$$\mathcal{R}(\tilde{f}) = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \text{Var}(Y) = a^2 \text{Var}(X) + \sigma^2,$$

avec $\text{Var}(X) = \frac{(35-15)^2}{12} = \frac{400}{12} \approx 33,33$, soit $\mathcal{R}(\tilde{f}) \approx 0,09 \times 33,33 + 0,25 \approx 3,25 \text{ kWh}^2$.

Simulation. Le script `exercice1/simulation.py` estime le risque réel de chaque prédicteur par son risque empirique sur un jeu de test de 2×10^6 points. On obtient :

	Valeur théorique	Risque empirique test
f^* (Bayes)	$R^* = 0,25$	0,2498
$\tilde{f}$ (constant)	3,25	3,2514

Conclusion. L'erreur de généralisation estimée de f^* (0,2498) est bien inférieure à celle de $\tilde{f}$ (3,2514), et elle est très proche du risque de Bayes théorique (0,25), l'écart ($\approx 2 \times 10^{-4}$) provenant uniquement de la taille finie de l'échantillon de test. Cela confirme à la fois que f^* est optimal et que le risque empirique sur un grand jeu de test est un bon estimateur du risque réel.

2 Risque de Bayes avec la perte absolue

Question 0 : Dérivée nulle sans extremum local

On prend $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^3$. Alors $f'(x) = 3x^2$, donc $f'(0) = 0$. Pourtant 0 n'est pas un extremum local : pour tout $\delta > 0$, $f(-\delta) = -\delta^3 < 0 = f(0) < \delta^3 = f(\delta)$, donc f prend des valeurs strictement inférieures et strictement supérieures à $f(0)$ dans tout voisinage de 0 (0 est un point d'inflexion).

Remarque (anticipation de la Q2). Une dérivée nulle n'est qu'une condition *nécessaire* d'extremum, pas suffisante. Dans la Q2, on ne se contentera donc pas d'annuler g' : on montrera que g est *convexe*, ce qui garantit qu'un point critique est bien un minimum global.

Question 1 : Un cas où $f_{\text{abs}}^* \neq f_{\text{sq}}^*$

Idée. Si la loi conditionnelle $Y | X = x$ est symétrique, sa moyenne et sa médiane coïncident, donc les deux prédicteurs de Bayes sont égaux. Pour les distinguer, il faut une loi conditionnelle **asymétrique**.

Cadre. On prend $X \sim \mathcal{U}([0, 1])$ et

$$Y = 2X + Z, \quad Z \sim \mathcal{E}(1) \text{ (loi exponentielle de paramètre 1),}$$

Z indépendant de X . La loi exponentielle est asymétrique : pour $Z \sim \mathcal{E}(1)$, $\mathbb{E}[Z] = 1$ et $\text{med}(Z) = \ln 2 \approx 0,693$.

D'après le cours et la Q2 qui suit, on a pour chaque x

$$f_{\ell_{\text{sq}}}^*(x) = \mathbb{E}[Y \mid X = x] = 2x + 1, \quad f_{\ell_{\text{abs}}}^*(x) = \text{med}(Y \mid X = x) = 2x + \ln 2.$$

Ces deux fonctions diffèrent (d'une constante $1 - \ln 2 \approx 0,307$), donc $f_{\ell_{\text{abs}}}^* \neq f_{\ell_{\text{sq}}}^*$.

Calcul analytique du risque absolu. Pour les deux prédicteurs, la partie $2x$ se simplifie : $\mathcal{R}_{\ell_{\text{abs}}}(g) = \mathbb{E}[|Y - g(X)|] = \mathbb{E}[|Z - c|]$ où c est la constante ajoutée ($c = 1$ pour la moyenne, $c = \ln 2$ pour la médiane). Un calcul direct donne, pour $Z \sim \mathcal{E}(1)$ et $c > 0$,

$$\mathbb{E}|Z - c| = \int_0^\infty |z - c|e^{-z} dz = c - 1 + 2e^{-c}.$$

On en déduit

$$\mathcal{R}_{\ell_{\text{abs}}}(f_{\ell_{\text{abs}}}^*) = \mathbb{E}|Z - \ln 2| = \ln 2 \approx 0,6931, \quad \mathcal{R}_{\ell_{\text{abs}}}(f_{\ell_{\text{sq}}}^*) = \mathbb{E}|Z - 1| = \frac{2}{e} \approx 0,7358.$$

Comme attendu, la médiane fait strictement mieux que la moyenne pour la perte absolue.

Vérification par simulation. Le script `exercice2/simulation.py` estime ces risques sur 5×10^6 points :

Prédicteur	$\mathcal{R}_{\ell_{\text{abs}}}$ (simu)	$\mathcal{R}_{\ell_{\text{abs}}}$ (théo)	$\mathcal{R}_{\ell_{\text{sq}}}$ (simu)
$f_{\ell_{\text{abs}}}^*$ (médiane = $2x + \ln 2$)	0,6935	0,6931	1,0959
$f_{\ell_{\text{sq}}}^*$ (moyenne = $2x + 1$)	0,7360	0,7358	1,0015

Conclusion. La médiane minimise le risque absolu ($0,6935 < 0,7360$) tandis que la moyenne minimise le risque quadratique ($1,0015 < 1,0959$) : chaque perte a bien son propre prédicteur de Bayes, et ils diffèrent dès que la loi conditionnelle est asymétrique.

Question 2 : Cas général : le prédicteur de Bayes de la perte absolue est la médiane

On fixe $x \in \mathcal{X}$ et on note $p = p_{Y|X=x}$ la densité conditionnelle (continue), $F(z) = \int_{-\infty}^z p(y) dy$ la fonction de répartition associée. On veut minimiser

$$g(z) = \int_{\mathbb{R}} |y - z| p(y) dy = \underbrace{\int_{-\infty}^z (z - y) p(y) dy}_{g_1(z)} + \underbrace{\int_z^{+\infty} (y - z) p(y) dy}_{g_2(z)}.$$

Bonne définition. L'hypothèse « $Y \mid X = x$ admet un moment d'ordre 1 » signifie $\int_{\mathbb{R}} |y| p(y) dy < \infty$. Comme $|y - z| \leq |y| + |z|$, l'intégrale définissant $g(z)$ converge pour tout z : g est bien définie sur $\mathbb{R}$.

Dérivation. Les deux intégrales ont une borne dépendant de z et un intégrande dépendant de z . On applique la règle de Leibniz. Pour g_1 , le terme de bord est $(z - y)p(y)|_{y=z} = 0$, donc

$$g_1'(z) = \underbrace{(z - z)p(z)}_{=0} + \int_{-\infty}^z \frac{\partial}{\partial z}(z - y)p(y) dy = \int_{-\infty}^z p(y) dy = F(z).$$

De même pour g_2 , le terme de bord $(y - z)p(y)|_{y=z} = 0$, et

$$g_2'(z) = -\underbrace{(z - z)p(z)}_{=0} - \int_z^{+\infty} p(y) dy = -(1 - F(z)).$$

Donc

$$g'(z) = F(z) - (1 - F(z)) = 2F(z) - 1.$$

Convexité et minimisation. Comme p est continue, F est dérivable et $g''(z) = 2F'(z) = 2p(z) \geq 0$. Ainsi g est **convexe**. Un point critique est donc un minimum global (c'est ici qu'intervient la mise en garde de la Q0 : la convexité transforme la condition nécessaire $g'(z) = 0$ en condition suffisante). On résout

$$g'(z) = 0 \iff 2F(z) - 1 = 0 \iff F(z) = \frac{1}{2}.$$

La valeur z telle que $F(z) = \frac{1}{2}$ est précisément une **médiane** de la loi conditionnelle. D'où

$$\boxed{f_{\ell_{\text{abs}}}^*(x) = \text{med}(Y \mid X = x)}.$$

(Si plusieurs z vérifient $F(z) = \frac{1}{2}$, ils forment un intervalle sur lequel g est constante et minimale ; tout point de cet intervalle convient.)

3 Espérance du risque empirique pour l'OLS

On se place dans le modèle linéaire à design fixe : $y = X\theta^* + \varepsilon$ avec $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2 I_n$, $X \in \mathbb{R}^{n \times d}$ injective ($d \leq n$), et $\hat{\theta} = (X^T X)^{-1} X^T y$. On rappelle l'objectif (Proposition 1) :

$$\mathbb{E}[R_n(\hat{\theta})] = \frac{n-d}{n} \sigma^2, \quad \text{où } R_n(\theta) = \frac{1}{n} \|y - X\theta\|^2.$$

Remarque. Les questions 2 à 6 calculent l'espérance du risque *empirique*, mesuré directement sur les données d'entraînement, $\mathbb{E}[R_n(\hat{\theta})] = \frac{n-d}{n} \sigma^2$. Le risque de généralisation, évalué sur un échantillon indépendant de même design, vaudrait au contraire $\frac{n+d}{n} \sigma^2 > \sigma^2$: c'est l'écart entre erreur d'apprentissage et erreur de test.

Question 1 : Comparaison au risque de Bayes

Dans ce modèle, le meilleur prédicteur possible est θ^* , et son risque (de design fixe) est $R_X(\theta^*) = \sigma^2$: c'est le **risque de Bayes**, égal à la variance du bruit irréductible. On compare :

$$\mathbb{E}[R_n(\hat{\theta})] = \frac{n-d}{n} \sigma^2 = \left(1 - \frac{d}{n}\right) \sigma^2 \leq \sigma^2 = R^*.$$

Le risque empirique espéré est plus petit que le risque de Bayes. Interprétation : c'est l'*optimisme* de l'erreur d'apprentissage. L'OLS ajuste ses d paramètres sur les données d'entraînement et capte donc une partie du bruit de ces données ; l'erreur mesurée *sur l'échantillon d'apprentissage* donne une valeur plus basse que l'erreur réelle, exactement d'un facteur $\frac{d}{n} \sigma^2$.

- Quand $d \ll n$: $\mathbb{E}[R_n(\hat{\theta})] \rightarrow \sigma^2$, l'erreur d'apprentissage est une bonne estimation de l'erreur réelle.
- Quand $d \rightarrow n$: $\mathbb{E}[R_n(\hat{\theta})] \rightarrow 0$, le modèle interpole les données (il apprend le bruit par cœur) : l'erreur d'entraînement devient nulle bien que l'erreur réelle ne le soit pas.

Question 2 : Réécriture avec la matrice de projection

On note $P = X(X^T X)^{-1} X^T$ la matrice de projection orthogonale sur $\text{Im}(X)$. Les prédictions sont $X\hat{\theta} = X(X^T X)^{-1} X^T y = Py$, donc le résidu vaut $y - X\hat{\theta} = (I_n - P)y$. En substituant $y = X\theta^* + \varepsilon$:

$$(I_n - P)y = (I_n - P)X\theta^* + (I_n - P)\varepsilon.$$

Or $(I_n - P)X = X - X(X^T X)^{-1} X^T X = X - X = 0$, donc le premier terme est nul. Ainsi $y - X\hat{\theta} = (I_n - P)\varepsilon$ et

$$R_n(\hat{\theta}) = \frac{1}{n} \|(I_n - P)\varepsilon\|^2 \implies \mathbb{E}[R_n(\hat{\theta})] = \mathbb{E}_\varepsilon \left[\frac{1}{n} \|(I_n - X(X^T X)^{-1} X^T)\varepsilon\|^2 \right].$$

Question 3 : $\sum_{i,j} A_{ij}^2 = \text{tr}(A^T A)$

Soit $A \in \mathbb{R}^{n \times n}$. Le coefficient diagonal j de $A^T A$ est $(A^T A)_{jj} = \sum_{i=1}^n (A^T)_{ji} A_{ij} = \sum_{i=1}^n A_{ij}^2$. En sommant sur j :

$$\text{tr}(A^T A) = \sum_{j=1}^n (A^T A)_{jj} = \sum_{j=1}^n \sum_{i=1}^n A_{ij}^2 = \sum_{(i,j) \in [1,n]^2} A_{ij}^2.$$

Question 4 : $\mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right] = \frac{\sigma^2}{n} \text{tr}(A^T A)$

On développe $\|A\varepsilon\|^2 = (A\varepsilon)^T (A\varepsilon) = \varepsilon^T A^T A \varepsilon = \sum_{i,j} (A^T A)_{ij} \varepsilon_i \varepsilon_j$. Par linéarité de l'espérance, et comme $\mathbb{E}[\varepsilon_i \varepsilon_j] = \sigma^2 \delta_{ij}$ (bruit centré, indépendant, de variance σ^2) :

$$\mathbb{E}_\varepsilon [\|A\varepsilon\|^2] = \sum_{i,j} (A^T A)_{ij} \mathbb{E}[\varepsilon_i \varepsilon_j] = \sigma^2 \sum_i (A^T A)_{ii} = \sigma^2 \text{tr}(A^T A).$$

En divisant par n : $\mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right] = \frac{\sigma^2}{n} \text{tr}(A^T A)$.

Question 5 : $A^T A = A$ pour $A = I_n - X(X^T X)^{-1} X^T$

A est symétrique. En notant $P = X(X^T X)^{-1} X^T$, et puisque $(X^T X)^{-1}$ est symétrique (inverse d'une matrice symétrique), $P^T = X((X^T X)^{-1})^T X^T = X(X^T X)^{-1} X^T = P$. Donc $A^T = I_n - P^T = I_n - P = A$.

A est idempotente. On a $P^2 = X(X^T X)^{-1} \underbrace{X^T X(X^T X)^{-1}}_{=I_d} X^T = X(X^T X)^{-1} X^T = P$,

d'où

$$A^2 = (I_n - P)^2 = I_n - 2P + P^2 = I_n - 2P + P = I_n - P = A.$$

En combinant : $A^T A = A A = A^2 = A$. □

Question 6 : Conclusion

En appliquant la Q4 avec la matrice $A = I_n - X(X^T X)^{-1} X^T$, puis la Q5 ($A^T A = A$) :

$$\mathbb{E}[R_n(\hat{\theta})] = \mathbb{E}_\varepsilon \left[\frac{1}{n} \|A\varepsilon\|^2 \right] = \frac{\sigma^2}{n} \text{tr}(A^T A) = \frac{\sigma^2}{n} \text{tr}(A).$$

Il reste à calculer $\text{tr}(A)$. Par la propriété de cyclicité de la trace, $\text{tr}(P) = \text{tr}(X(X^T X)^{-1} X^T) = \text{tr}((X^T X)^{-1} X^T X) = \text{tr}(I_d) = d$. Donc

$$\text{tr}(A) = \text{tr}(I_n) - \text{tr}(P) = n - d, \quad \boxed{\mathbb{E}[R_n(\hat{\theta})] = \frac{n-d}{n} \sigma^2.}$$

On retrouve bien la Proposition 1. (On peut noter que $\text{tr}(P) = d$ est cohérent avec le fait que P projette sur $\text{Im}(X)$, de dimension d : la trace d'un projecteur orthogonal est la dimension de son image.)

Question 7 : Espérance de $\|y - X\hat{\theta}\|^2/(n - d)$

On a $\|y - X\hat{\theta}\|^2 = n R_n(\hat{\theta})$, donc $\mathbb{E}[\|y - X\hat{\theta}\|^2] = n \mathbb{E}[R_n(\hat{\theta})] = n \cdot \frac{n-d}{n} \sigma^2 = (n - d) \sigma^2$. Par conséquent

$$\mathbb{E}\left[\frac{\|y - X\hat{\theta}\|^2}{n - d}\right] = \sigma^2.$$

Autrement dit, $\hat{\sigma}^2 := \frac{\|y - X\hat{\theta}\|^2}{n - d}$ est un estimateur **sans biais** de σ^2 . Le dénominateur $n - d$ (et non n) corrige précisément l'optimisme mis en évidence à la Q1.

Question 8 : Estimation numérique de σ^2

Le script `exercice3/simulation.py` simule un modèle linéaire à design fixe ($n = 200$, $d = 50$, $\sigma^2 = 4$, X et θ^* tirés une fois), répète 2000 fois le tirage du bruit, ajuste l'OLS et calcule $\hat{\sigma}^2 = \|y - X\hat{\theta}\|^2/(n - d)$.

Quantité	Valeur
σ^2 théorique	4,0000
moyenne de $\hat{\sigma}^2$	4,0041
écart type de $\hat{\sigma}^2$	0,4441
estimateur biaisé $\ \cdot\ ^2/n$ (moyenne)	3,0031
valeur attendue $\frac{n-d}{n} \sigma^2$	3,0000

Conclusion. La moyenne de $\hat{\sigma}^2$ (4,004) coïncide avec la valeur théorique $\sigma^2 = 4$ (biais relatif 0,1%), ce qui valide le caractère sans biais de l'estimateur. À l'inverse, l'estimateur naïf qui divise par n donne $3,003 \approx \frac{n-d}{n} \sigma^2 = 3$: il donne toujours une valeur plus basse que σ^2 , exactement comme le prédit la théorie.

4 Régression sur un jeu de données fourni

Exercice de code. Le détail du code et des graphiques est dans le notebook de l'exercice 4, on résume ici la démarche suivie et les résultats obtenus.

Cadre. Le jeu de données est composé de quatre tableaux : X_{train} et X_{test} dans $\mathbb{R}^{200 \times 200}$, y_{train} et y_{test} dans $\mathbb{R}^{200}$. On a donc autant de variables que d'observations ($d = n = 200$), une situation délicate pour une régression classique. On compare trois modèles : régression linéaire, Ridge et Lasso. Les variables sont standardisées, en calculant la moyenne et l'écart type uniquement sur le train, puis en les appliquant au test. Le coefficient de régularisation de Ridge et de Lasso est choisi par validation croisée à 5 plis, toujours sur le train.

Résultats.

Modèle	R^2 train	R^2 test	MSE test
Régression linéaire	1,0000	-9,9240	8,0421
Ridge	0,9891	0,7141	0,2105
Lasso	0,9593	0,9231	0,0566




FIGURE 1 – Valeurs prédites en fonction des valeurs réelles sur le jeu de test, pour les trois modèles.

Conclusion. Le Lasso donne le meilleur résultat, avec un R^2 de test de 0,923, largement supérieur à l’objectif de 0,88 et proche du R^2 d’environ 0,92 annoncé pour le prédicteur de Bayes. Il ne garde que 38 variables sur les 200 de départ. La figure montre bien le problème : la régression linéaire colle parfaitement au train ($R^2 = 1$) mais devient très mauvaise sur le test (R^2 fortement négatif), car avec $d = n$ elle a la place d’apprendre le bruit du train par cœur. Ridge règle en partie ce problème mais garde toutes les variables, ce qui limite ses performances. Lasso fait mieux car il met à zéro la plupart des coefficients, ce qui montre que seules quelques variables comptent vraiment pour prédire y .

5 Classification sur un jeu de données fourni

Exercice de code. Le détail du code et des graphiques est dans le notebook de l’exercice 5, on résume ici la démarche suivie et les résultats obtenus.

Cadre. C’est un problème de classification binaire, avec X_{train} et X_{test} dans $\mathbb{R}^{2000 \times 30}$. Les classes sont presque équilibrées : prédire toujours la classe majoritaire donne déjà une accuracy de test de 0,559, c’est notre repère de base. On compare trois modèles de familles différentes : régression logistique, K plus proches voisins et SVC à noyau RBF. Les variables sont standardisées et les hyperparamètres sont choisis par recherche sur grille en validation croisée à 5 plis, sur le train uniquement.




FIGURE 2 – Projection PCA 2D du jeu d'entraînement, coloriée par classe.

Les deux classes se recouvrent beaucoup sur cette projection, il n'y a pas de séparation nette. Cela laisse penser qu'une accuracy proche de 1 ne sera pas possible sur ce jeu de données.

Résultats.

Modèle	Accuracy CV	Accuracy train	Accuracy test
Régression logistique	0,716	0,721	0,745
K plus proches voisins	0,747	0,767	0,778
SVC (noyau RBF)	0,770	1,000	0,800



FIGURE 3 – Accuracy train et test par modèle, comparée à l'objectif de 0,85.




FIGURE 4 – Matrice de confusion du SVC (meilleur modèle) sur le jeu de test.

Conclusion. Le SVC à noyau RBF est le meilleur modèle, avec une accuracy de test de 0,800. Aucun des trois modèles ne dépasse vraiment ce niveau (entre 0,745 et 0,800 de test) : les classes se recouvrent trop, comme on le voit sur la projection PCA, ce qui fixe une limite autour de 0,20 d’erreur quelle que soit la méthode utilisée. On remarque aussi que le SVC apprend le train par cœur (accuracy de 1,000) sans que cela l’empêche de bien généraliser, ce qui montre que le problème vient des données et non d’un modèle mal réglé. L’objectif de 0,85 n’est donc pas atteint ici, même après avoir réglé les hyperparamètres par validation croisée sur tous les modèles recommandés.

6 Application de l’apprentissage supervisé

Exercice de code. Le détail du code et des graphiques est dans le notebook de l’exercice 6, on résume ici la démarche suivie et les résultats obtenus.

Cadre. Le jeu de données vient de Kaggle (*Smartphone Specifications and Pricing Dataset*) et contient 1 000 000 de smartphones générés de façon synthétique, décrits par 33 variables (marque, processeur, RAM, écran, batterie, appareils photo, etc.). Le but est de prédire le prix en roupies indiennes à partir des caractéristiques techniques du téléphone. C’est un problème de régression qui peut par exemple aider à fixer le prix d’un nouveau modèle ou à repérer une annonce mal placée sur le marché.

Prétraitement. La variable qui liste les types de capteurs photo est transformée en plusieurs colonnes binaires, une par type de capteur. Les autres variables catégorielles sont transformées en indicatrices binaires, une colonne par catégorie. Les variables numériques sont standardisées. On sépare le jeu de données en train et test, avec 80% pour le train et 20% pour le test.




FIGURE 5 – Corrélations entre variables numériques et le prix. Les scores CPU et GPU se distinguent nettement des autres variables.

Modèles. On compare une régression Ridge (la classe `RidgeCV`, qui choisit le coefficient de régularisation par validation croisée à 5 plis) et un modèle de gradient boosting par histogrammes (`HistGradientBoostingRegressor`), adapté à un jeu d'un million de lignes. Son taux d'apprentissage est comparé par validation croisée à 3 plis sur un échantillon du train.

Résultats.

Modèle	R^2 train	R^2 test	MAE test (Rs)	temps d'entraînement (s)
Ridge	0,9863	0,9865	2326	6,9
HistGradientBoosting	0,9881	0,9881	2155	9,2




FIGURE 6 – Prix prédit en fonction du prix réel sur le jeu de test, pour les deux modèles.




FIGURE 7 – Coefficients Ridge les plus importants (variables standardisées).

Conclusion. Les deux modèles généralisent bien, les scores sont presque les mêmes sur le train et sur le test. Le Ridge, qui est pourtant un modèle linéaire, explique déjà 98,6% de la variance du prix : dans ce jeu de données, le prix suit une relation presque linéaire avec les caractéristiques du téléphone, surtout les scores de processeur et de carte graphique. Le gradient boosting fait un peu mieux (+0,2 point de R^2 , MAE réduite d'environ 7%), ce qui montre qu'il reste quelques effets non linéaires que le modèle linéaire ne capture pas. Le gain reste modeste pour un temps

d'entraînement environ un tiers plus long.

7 Application de l'apprentissage non supervisé

Exercice de code. Le détail du code et des graphiques est dans le notebook de l'exercice 7, on résume ici la démarche suivie et les résultats obtenus.

Cadre. Le jeu de données vient de Kaggle (*Spotify Tracks Dataset*) et contient 114 000 morceaux répartis sur 114 genres, décrits par 12 variables audio : dansabilité, énergie, intensité sonore (en décibels), tempo (en battements par minute), valence, etc. Le but est de regrouper les morceaux par profil audio, sans utiliser le genre, puis de vérifier si les groupes obtenus ont un sens musical. C'est un problème de clustering.

Méthode. Les variables sont standardisées. Une projection PCA en deux dimensions ne montre aucun groupe vraiment séparé, la musique forme plutôt un continuum. Le nombre de clusters $k = 8$ est choisi en combinant la méthode du coude, le score de silhouette pour KMeans et le critère BIC pour un mélange gaussien (GMM). On compare ensuite KMeans et un GMM à covariance pleine avec cette valeur de k .




FIGURE 8 – Choix du nombre de clusters k : méthode du coude et score de silhouette. Aucun coude net n'apparaît, cohérent avec une structure continue.

Résultats.

Modèle	Score de silhouette	ARI (vs. genres)
KMeans ($k = 8$)	0,154	0,012
GMM plein ($k = 8$)	0,056	0,008




FIGURE 9 – Projection PCA 2D des morceaux, coloriée par cluster, pour KMeans et pour GMM.




FIGURE 10 – Profil audio moyen par cluster KMeans (valeurs normalisées), utilisé pour l'interprétation musicale des groupes obtenus.

Conclusion. Le score de silhouette est faible pour les deux méthodes, ce qui confirme qu'il n'y a pas de clusters bien séparés : comme le montrait la projection PCA, la musique forme un continuum plutôt que des catégories bien distinctes. L'ARI est bas aussi, mais c'est normal puisque 8 clusters ne peuvent pas retrouver 114 genres, ce n'était de toute façon pas l'objectif. Malgré cela, en regardant les genres dominants dans chaque cluster, on trouve des regroupements qui ont un sens musical : un cluster plutôt acoustique, un cluster électronique et dansant, un cluster où les morceaux sont surtout parlés, proche du rap. Le clustering capture donc une structure plus large que le genre, qui peut servir par exemple pour des recommandations ou des playlists automatiques.